

**Hochschule Karlsruhe
Technik und Wirtschaft**
UNIVERSITY OF APPLIED SCIENCES

GENETISCHE ALGORITHMEN ZUR OPTIMIERUNG VON HYPERPARAMETERN EINES KÜNSTLICHEN NEURONALEN NETZES

Fakultät für Maschinenbau und Mechatronik
der Hochschule Karlsruhe
Technik und Wirtschaft

Bachelorarbeit

vom 01.03.2018 bis zum 31.08.2018
vorgelegt von

Christian Heinzmann
geboren am 18.02.1995 in Heilbronn
Matrikelnummer: 52550

Winter Semester 2019

Professor	Prof. Dr.-Ing. habil. Burghart
Co-Professor	Prof. Dr.-Ing. Olawsky
Betreuer FZI:	M. Sc. Kohout

Eigenständigkeitserklärung und Hinweis auf verwendete Hilfsmittel

Eigenständigkeitserklärung und Hinweis auf verwendete Hilfsmittel. Hiermit bestätige ich, dass ich den vorliegenden Praxissemesterbericht selbständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die Stellen des Berichts, die dem Wortlaut oder dem Sinn nach anderen Werken entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht.

Datum: _____ Unterschrift: _____

Ausschreibung

BACHELORARBEIT

Genetische Algorithmen zur Optimierung von Hyperparametern eines künstlichen neuronalen Netzes

Zur Vermeidung der weiteren Ausbreitung von multiresistenten Keimen in Einrichtungen des Gesundheitswesens (insb. Krankenhäuser) werden am FZI Systeme und Methoden entwickelt, welche helfen sollen die Händehygiene-Compliance von Mitarbeitern dort zu erhöhen. Durch technische Unterstützung bei häufig wiederkehrenden Maßnahmen, soll mehr Zeit geschaffen und gleichzeitig auf die Wichtigkeit von Desinfektionsmaßnahmen aufmerksam gemacht werden. Dies soll mit Hilfe von Augmented-Reality umgesetzt werden. Dabei ist das Ziel, bekannte Prozesse, wie beispielsweise den Wechsel von postoperativen Wundverbänden, visuell zu unterstützen und automatisch zu dokumentieren.

AUFGABEN

Im Kontext der Detektion von Aktionen und Objekten, soll die Optimierung von Neuronalen Netzen mit Genetischen Algorithmen durchgeführt werden. Das Ziel hierbei ist es, ein Framework zu entwickeln und zu implementieren, in welchem künstliche neuronale Netze automatisiert trainiert werden. Unter anderem sollen die Hyperparameter mit Hilfe von Genetischen Algorithmen intelligent angepasst und das trainierte Netz anschließend ausgewertet werden. Diese Aufgaben sollen voll automatisiert ablaufen. Daraus ergeben sich folgende Aufgaben:

- Literaturrecherche über aktuelle Genetische Algorithmen und aktuelle Neuronale Netze
- Einarbeiten in vorhandene Frameworks für Genetische Algorithmen und Neuronale Netze
- Konzeptionierung und Implementierung des ausgewählten Ansatzes zur Optimierung von Hyperparameter des Neuronalen Netzes
- Evaluation und Auswertung speziell unter der Beachtung geringer Datenmengen
- Wissenschaftliche Aufbereitung und Dokumentation des Projekts

WIR BIETEN

- Aktuelle Softwaretools im täglichen wissenschaftlichen Einsatz
- eine angenehme Arbeitsatmosphäre
- konstruktive Zusammenarbeit

WIR ERWARTEN

- Grundkenntnisse in maschinellem Lernen
- Kenntnisse in folgenden Bereichen sind von Vorteil: Python, Tensorflow, C/C++
- selbständiges Denken und Arbeiten
- sehr gute Deutsch- oder Englischkenntnisse
- Motivation und Engagement

ERFORDERLICHE UNTERLAGEN

Wir freuen uns auf Ihre PDF-Bewerbung an Herrn Lukas Kohout, kohout@fzi.de, mit folgenden Unterlagen:

- aktueller Notenauszug
- tabellarischer Lebenslauf

WEITERE INFORMATIONEN

- Start: ab sofort

Inhaltsverzeichnis

Eigenständigkeitserklärung und Hinweis auf verwendete Hilfsmittel	2
Ausschreibung	3
1 Einleitung	6
1.1 Motivation	6
1.2 Aufgabenstellung	6
1.3 Aufbau der Arbeit	7
2 Grundlagen	8
2.1 Optimierungsgrundlagen	8
2.2 Genetische Algorithmen	8
2.2.1 Aufbau und Initialisierung einer Population	9
2.2.2 Fitnessfunktion (eng. Fitnessfunction or grade)	10
2.2.3 Selektion der Eltern (eng. Select Parents)	10
2.2.4 Vermehrung (eng. Breed)	12
2.2.5 Neue Generation	14
2.3 Künstliche Neuronale Netze	15
2.3.1 Aufbau eines Neurons	15
2.3.2 Struktureller Aufbau eines Neuronalen Netzes	17
2.3.3 Verlustfunktion aka lossfunktion	17
2.3.4 Optimierer alt Gradientenabstieg	17
2.3.5 Hyperparameter	17
2.4 Zusammenfassung	18
3 Stand der Forschung und Technik	19
3.1 Forschung	19
3.2 Anwendung	19
3.3 Zusammenfassung	19
4 Konzept	20
4.1 Anforderungsanalyse	20
4.2 Genetischer Algorithmus	20
4.2.1 Eltern auswahl	20
4.3 Zusammenfassung	20
5 Implementierung	21
5.1 Systemaufbau	21
5.2 Zusammenfassung	21
6 Evaluation und Tests	22
6.1 Einleitung	22

6.2	Testszenarien	22
6.3	Evaluation	22
6.4	Ergebniss und Interpretation	22
6.5	Zusammenfassung	22
7	Zusammenfassung und Ausblick	23
7.1	Einleitung	23
7.2	Zusammenfassung	23
7.3	Bedeutung der Arbeit	23
7.4	Ausblick	23

Abbildungsverzeichnis

1	Ablaufdiagramm eines Genetischen Algorithmuses mit 5 Schritten	9
2	Beispiel einer Polulation mit 4 induviduen (Chromsomen) welche vier bi-näre Gene besitzen [1]	10
3	Rouletterad mit Proportionalen Anteil der Individuen anhand ihrere Fitness	11
4	Tunier Selektion mit $k = 3$ Individuen und dem Gewinner Individuum 3 .	12
5	crossover anhand eines einfachen binären Chrms. Das erste zeigt eine 50/50 crossover. Das zweite zeigt eine Zufällige auswahl ders Gens.[1] . . .	13
6	Muation eines Genes um höhere vielfältigkeit zubekommen.[1]	14
7	Künstliches Neuronales Netz mit drei Schichten je drei Neuronen [1] . . .	15
8	Aufbau eines Neurons [1]	16

Abkürzungsverzeichnis

1 Einleitung

1.1 Motivation

Nach einer Studie der Charité aus dem Jahr 2015 sterben in Europa jährlich 23.000 Menschen an den Folgen einer Infektion mit multiresistenten Keimen. Die Tendenz ist dabei steigend. Hauptursache für die Ausbreitung dieser Keime, wie beispielsweise MRSA, ist eine mangelnde Hygiene der Angestellten in den Versorgungseinrichtungen beim Umgang mit den Patienten. Ziel des Projekts HEIKE ist es neue, technikgestützte Möglichkeiten zu entwickeln, welche die behandelnden Mitarbeiter im Krankenhausumfeld bei Maßnahmen am Patienten unterstützen. [2]

Um diese Automatischen System, meist Deep Learning Methoden, zu trainieren braucht es sehr große Datensätze und viele individuelle Hyperparameter. Momentan werden diese meist nach groben Ermessen des Entwicklers ausgewählt. Das Auswählen und Testen beansprucht sehr viel Zeit und Mühe.

1.2 Aufgabenstellung

Ziel der Arbeit ist es, zunächst die Optimierung von Hyperparametern zu vereinfachen. Dazu ist eine Automatisierter Trainings und Auswertvorgang nötig. Anschließend sollen die Hyperparameter mit Hilfe von Genetischen Algorithmen noch verbessert werden. Um schneller bessere Ergebnisse zu erhalten. Diese Ergebnisse sollen dann einer klassischen Grid Search gegenübergestellt werden.

Um dies zu vereinfachen soll ein Konzept geschaffen werden, welches die Vorgänge automatisiert und optimiert. Dabei geht es hauptsächlich um den Vorgang der Auswahl von Hyperparameter und die Auswahl der Dimension eines Künstlichen Neuronalen Netzes. Diese berechneten Werte sollen gespeichert und anschließend übersichtlich angezeigt werden. Wodurch sich die idealen Parameter herausbilden. Diese Ergebnisse sollen dem momentanen Ansatz gegenübergestellt werden.

(Mit diesem Ansatz kann die Dimensionierung eines Netzes einfacher umgesetzt werden.) Ein weiterer Anwendungsfall ist die Hyperparameterauswahl, mit Hilfe dieses Werkzeugs soll eine einfachere und bessere Auswahl der Hyperparameter erfolgen. Diese berechneten Werte sollen gespeichert und anschließend übersichtlich und intuitiv angezeigt werden. Wodurch sich die idealen Parameter herausbilden. Mit diesem Ansatz soll die Richtigkeit des Netzes erhöht werden, sodass es bessere Ergebnisse liefert. Dieses Werkzeug soll konzipiert und implementiert werden. Anschließend soll eine Evaluation und Auswertung über die mögliche Verbesserung durchgeführt werden.

1.3 Aufbau der Arbeit

Zunächst wird im zweiten Kaptiel auf die verwendeten Grundlagen eingegangen. Zunächst wird im zweiten Kaptiel auf die Grundlagen zu Genetischen Algorithmen und Künstlichen Neuronalen Netzen eingegangen.

Welche Algorythmen bei dieser Arbeit verwendet werden. Und mit welchen Künstlichen Neuronalen Netzen diese Optimierungs Algorithmen getestet werde. Außerdem wird in Abschnitt 3 auf den Momentanen Stand der Technik und Forschung eingegangen dort werden auch einige Anwendungsbeispiele der Genetischen Algorithmen genannt. Nun folgt in Kapitel 4 die ausarbeitung des Konzeptes mit erklärungen der einzelnen Ideen. Darauf aufbauend kommt Implementierung in Kapitel 5 in welcher mit psyodocode erklärt wird wie die Arbeit umgesetzt wurde. Anschließend wird das Implementierte system Evaluirt und getestet. Zum Schluss in Kapitel 7 gibt es eine Zusammenfassung

2 Grundlagen

In diesem Kapitel werden die theoretischen Grundlagen, die zum Verständnis, der vorliegende Arbeit wichtig sind beschrieben. Zuebeginn erfolgt eine kurzer einstieg in die Optimierungsgrundlagen. Dann folgt die Einführung in die Grundlagen der genetischen Algorithmen. Anschließend werden die wichtigen Grundlagen der Künstlichen neuronalen Netzen erklärt. Zum Schluss wird kurz auf die Hyperparameter eingegangen.

2.1 Optimierungsgrundlagen

Angenommen es soll ein Künstliches Neuronales Netz mit k Layern und L Neuronen zur Klassifizierung von einfachen handgeschriebenen Zahlen erstellt werden. Der Entwickler entscheidet sich für ein 3 Layern Netz mit jeweils 3 Neuronen. Nach dem Training hat es die Genauigkeit von 85 Prozent. Ist dies Akzeptabel? Kann man sagen, das für $k = 3$ bzw. $j = 3$ die optimale Lösung gefunden wurde? Um dies zu beurteilen müssen viele Experimente durchgeführt werden. Die Frage ist, wie man den die besten Werte für k und j finden um die Klassifizierung zu maximieren. Dieser Vorgang wird als Hyperparameter-Optimierung bezeichnet. Bei der Optimisierung wird mit einem Inizialwert gestartet dieser ist in den seltensten Fällen die exakte Lösung. Dieser Inizialwert muss einige male verändert werden um auf einen Optimum zu kommen. Manchmal ist dieses Anpassen/optimieren so Komplex, dass es durch eine Funktion ersetzt werden muss.

2.2 Genetische Algorithmen

Die Inhalte des folgenden Abschnittes sind, sofern nicht anderweitig angeführt aus den Gurndlagen büchern xxxx und xxxx übernommen.

Genetische Algorithmen sind heuristische Suchansätze. Im wesentliche zeichnet sie eine probabilistische Eltern Selektion als primären Suchoperator aus. Als Weitem Suchoperator kann noch auf die Mutation zurückgegriffen werden, dieser garantiert eine Erreichbarkeit aller Punkte im Suchraum und erhält die Grunddiversität in der Population. Es gibt zwei verschiedene Algorithmen der Standart-GA tauscht nach einer Generation die komplette Elternpopulation durch die Kinderpopulation aus. Und bestehen in der Regel immer aus fünf gleichen Schritten wie in Abb. 1 zusehen ist. Im Gegensatz dazu gibt es den Steady-State-GA welcher durch seine überlappende Population auszeichnet, dieser Algorithmus wird in der Arbeit nicht verwendet und wird deswegen nicht weiter erklärt.

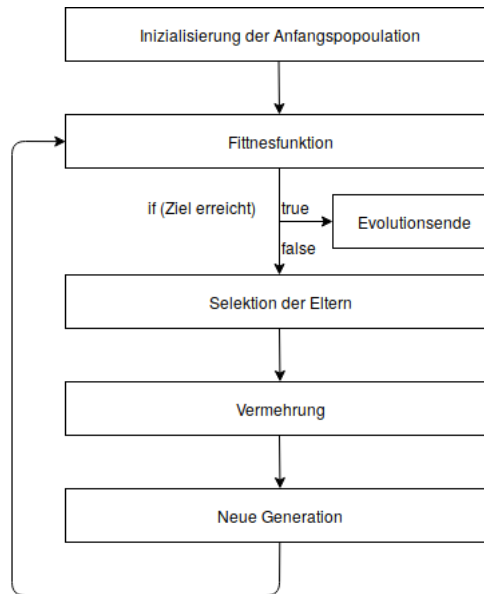


Abbildung 1: Ablaufdiagramm eines Genetischen Algorithmuses mit 5 Schritten

Der Standard genetische Algorithmus 1 besteht aus folgenden 5 Schritte: Schritt 1, Initialisieren einer Population. Schritt 2, Fitness berechnen mit Hilfe der Fitnessfunktion. Schritt 3, Selektieren der Eltern. Schritt 4, Vermehren durch Cross-over und Mutation. Schritt 5, Austausch der Populationen. In den nachfolgenden Unterkapiteln werden auf die einzelnen Schritte genauer eingegangen.

2.2.1 Aufbau und Initialisierung einer Population

Der klassische genetische Algorithmus basiert auf einer Reihe von Kandidatenlösungen. Die Größe der Population ist somit auch die Anzahl der Lösungen. Jede Lösung kann als einzelnes Individuum gesehen werden und wird durch ein Chromosomenstrang repräsentiert. Ein Chromosom besteht wiederum aus vielen Genen, welche die Parameter/hyperparameter repräsentieren. Der Aufbau ist grafisch in Figure 2 gut zu erkennen. Es gibt verschiedene Möglichkeiten, diese Gene dazustellen. Wie Binär oder dezimal, um die Grundlagen nahe des später folgenden Konzepts zuhalten, wird der Ablauf per Dezimal-Genen erklärt.




Abbildung 2: Beispiel einer Polulation mit 4 induviduen (Chromsomen) welche vier binäre Gene besitzen [1]

Diese Anfangspopulation(Generation 0) wird zufällig initialisiert, um die größt mögliche Abdeckung des Suchraums zu gewähren.

Die erste Generation besitzt (dadurch) eine sehr geringe Fitness, dies verbessert sich aber im Lauf des Trainings. Die erste Generation besitzt eine sehr geringe Fittnes, welche im verlauf des Trainings stetig steigert bis sie das Maximum erreicht.

— würde ich weglassen Durch Selection werde die nicht unnötigen/Contra-produktiven Individumen oder auch Unfittesten Individuen aussotiert. Dafür wird die Fittneswert benötigt, welches im nächsten Punkt erklärt wird. —

2.2.2 Fitnessfunktion (eng. Fitnessfunction or grade)

Die Fitnessfunktion bewertet das Individuum anhand seiner Funktionstauglichkeit, bezogen auf die vorhandene Aufgabe. Dabei werden nicht einzelnen Gene bewertet, sondern das ganze Genom/Chromosom/Individuum. Es gibt keine universelle Fitnessfunktion, diese muss also für jede Anwendung speziell geschrieben werden. Es wird also nicht berücksichtigt welches Gene sich positiv bzw. negativ auswirken. Als Rückgabewert gibt die Fitnessfunktion uns einen dezimalen/float Fitnesswert, dabei steht ein höherer Fitnesswert steht für eine höher Qualität an Individuum sprich bessere Lösung.

2.2.3 Selektion der Eltern (eng. Select Parents)

Bei dem Schritt Selektion geht es, darum einen Elternpool zu erstellen, aus welchem die neue Generation erstellt wird. Deshalb ist es wichtig, nur die besten, geeignetesten Individuen auszuwählen. Es gibt verschiedene Ansätze bei der Selektion, die bedeuteten werden genannt und erläutert.

Informationen wurden aus dem Paper [3] entnommen.

- **Auswahl proportional zu Fitness (eng. Fitness Proportional Selection (FPS))**, hierbei spielt die im vorigen Schritt berechnete Fitness eine große Rolle. Die Eltern werden nach ihrer Fitness proportional ausgewählt und zum Elternpool hinzugefügt. Wenn $f(a_i)$ die Fitness des Individuums a_i in der Population ist, dann ist die Wahrscheinlichkeit selektiert/ausgewählt zu werden:

$$ps(a_i) = \frac{f(a_i)}{\sum_{j=1}^n f(a_j)}; j \in 1, 2, \dots, n \quad (1)$$

wobei n die Anzahl der Individuen einer Population ist. Diese Wahrscheinlichkeit ps kann man sich, als Anteil auf einem Rouletterad, wie in Abbildung 4, vorstellen. Auf dem dann zufällig die Eltern aus den Individuen a_1, \dots, a_n "ausgedreht" werden. Problem hier ist, dass Individuen, die am Anfang gut sind, schnell die ganze Population übernehmen. Das kann dazu führen, dass eine mögliche bessere Lösung durch den Algorithmus im Suchraum nicht gefunden wird.




Abbildung 3: Rouletterad mit proportionalen Anteilen der Individuen anhand ihrer Fitness

introduction to evolutionary computing 80

- **Ranking Selektion**, diese Selektion wurde von Backer als Verbesserung der Fitness Proportional Selection entwickelt [4]. Dabei werden die Eltern nicht direkt nach ihrer Fitness ausgewählt. Die Fitness dient nur zum Einteilen in eine Rangliste. Anhand dieser Rangliste wird dann wieder mit Hilfe des Rouletterades ausgewählt. Dabei gibt es verschiedene Verfahren, wie diese Verteilung aussehen kann, einmal ein Lineares Ranking-Verfahren:

$$p_i = \frac{1}{N} (n^- + (n^+ - n^-) \frac{i - 1}{N - 1}); i \in 1, \dots, N \quad (2)$$

Wobei p_i die Wahrscheinlichkeit, dass das i -te Individuum selektiert zu werden. $\frac{n^-}{N}$ ist die Wahrscheinlichkeit, dass das schlechteste Individuum selektiert zu werden und $\frac{n^+}{N}$ ist die Wahrscheinlichkeit, dass das beste Individuum selektiert zu werden.

oder das exponentielle Ranking:

$$p_i = \frac{c^{N-i}}{\sum_{j=1}^N c^{N-j}}; i \in 1, \dots, N \quad (3)$$

die Summe $\sum_{j=1}^N c^{N-j}$ normalisiert die Wahrscheinlichkeit um sicherzustellen das $\sum_{i=1}^N p_i = 1$ Wobei die Berechnungen 2 und 3 nur den Anteil eines Individuums auf dem Rouletterades verändern.

- **Tunier selektion**, in diesem Verfahren werden zufällig k Individuen der Population ausgewählt. Diese k Individuen treten wie in einem Turnier gegeneinander an. Der Gewinner ist das Individuum mit dem besten Fitnesswert, dieser wird dann auch als Elternteil ausgewählt. Hierbei wird auf den Elternpool verzichtet und direkt ein Kind aus zwei Gewinnern erstellt. Eingesetzt wird dies bei kleineren Populationen mit weniger als 20 Individuen.

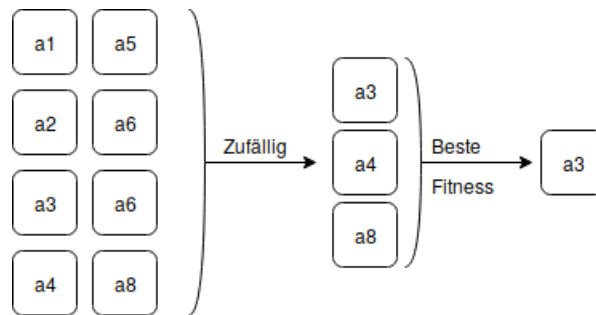


Abbildung 4: Tunier Selektion mit $k = 3$ Individuen und dem Gewinner Individuum 3

2.2.4 Vermehrung (eng. Breed)

Aus dem Elternpool/ Paarungspool werden nun Nachkommen(Kinder) geschaffen. Alleine durch die Paarung(eng. Crossover) von qualitativ hochwertigen Individuen wird erwartet, dass die Nachkommen eine bessere Qualität besitzen als die ihrer Eltern. Als zweite Verbesserung wird noch die Mutation einzelner Gene angewendet. Für Crossover und Mutation gibt es verschiedene Ansätze, die in diesem Abschnitt genauer erklärt werden.

Crossover , nennt man die Operation, bei der die Chromostränge der Kinder Individuen zusammengesetzt werden. Beim Crossover gibt es mehrer Varianten, die One-Point-Crossover in welchem zufällig ein Punkt im Chromosomenstrang festgelegt wird. Ab diesem Punkt wird der Chromosomenstrang dann aufgeteilt und anschließend mit dem Crossover des anderen Elternteils wieder zusammen gesetzt. Ein einfaches Beispiel ist im Oberenteil der Abbildung 5 zu sehen.

Eine Abwandlung des one-point-crossover ist das zwei-punkt-crossover oder k-point-crossover. Hier wird der Chromsomenstrang an k punkten aufgeteilt und anschließend wieder zusammengesetzt. In mittleren Teil der Abbildung 5 ist ein $k = 2$ Crossover zu sehen.

Eine weite Grundlegende Operation beim Crossover ist die Uniformcrossover [5] in welcher es keine festgelegten punkte gibt. Hier wird für jedes Gen zufällig entschieden aus welchem Elternteil das Gen entnommen wird. Dies im unteren Teil der Abbildung 5 noch einmal veranschaulicht.

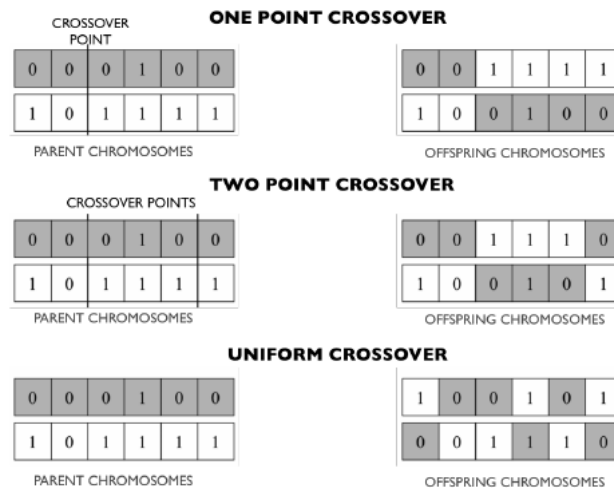


Abbildung 5: crossover anhand eines einfachen binären Chrms. Das erste zeigt eine 50/50 crossover. Das zweite zeigt eine Zufällige auswahl ders Gens.[1]

Crossover nach dem Paper [6].

Mutation ,hierbei wird jedes Gen des Individuums zufällig mit einer zufälligen Mutation versehen. Durch diese Mutation wird eine höhere Diversität in die nachfolgende Generation übergeben. Diese Mutation macht es möglich einen größeren Suchraum abzudecken und somit die Werte genauer anzupassen, um so auf die Optimale Lösung zu kommen.




Figure 4-5. Uniform mutation for a solution with more than two values for its genes

Abbildung 6: Mutation eines Genes um höhere Vielfaltigkeit zu bekommen.[1]

2.2.5 Neue Generation

Die neue Generation aus Kindern tauscht nun die alte Generation aus. Anschließend folgen die gleichen Schritte so lange bis die gewünschte Abbruchbedingung/ Fitnesswert erreicht ist. Aus dieser letzten Generation kann das beste Individuum ausgesucht werden und als beste Lösung weiter verwendet werden.

2.3 Künstliche Neuronale Netze

Künstliche Neuronale Netze sind dem natürlichen Vorbild der neuronalen Netze im Gehirn nachempfunden. Beide Netze setzen sich aus einzelnen Neuronen zusammen, welche mit einander verbunden sind. Wie man in Figure 7 sieht ist jede Schicht ist aus einzelnen Neuronen aufgebaut welche mit den Neuronen der nächsten Schicht verbunden sind, diese Verbindungen repräsentieren die Gewichte, über diese kann einem Netz verschiedene Zusammenhänge von Input und Output antrainiert bzw. angelernt werden.

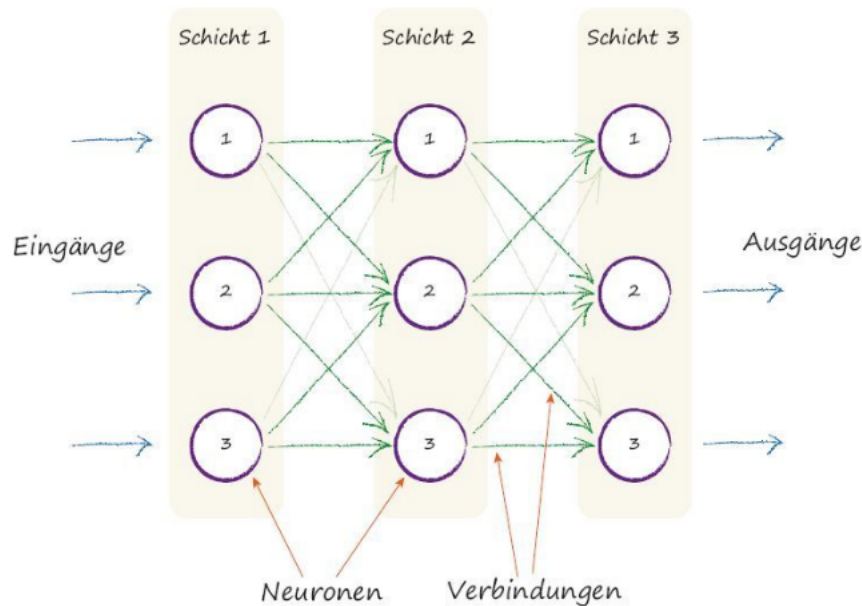


Abbildung 7: Künstliches Neuronales Netz mit drei Schichten je drei Neuronen [1]

Im folgenden Kapitel wird zuerst der Aufbau eines Neurons/Perseptron erklärt. Anschließend wird auf den strukturellen Aufbau eines Künstlichen Neuronalen Netzes nähergebracht. Zum Schluss werden noch wichtige Eigenschaften wie die Verlustfunktion und der Gradienten abstieg eingegangen sowie auf die Hyperparameter, welche für die Arbeit essentiell sind.

Grundlagen aus dem buch ArificalNeuroalNetworks s.11

2.3.1 Aufbau eines Neurons

Eingang Bei dem Input handelt es sich um einfache xxxFloatwert dieser wird mit den einzelnen Gewichten verrechnet. Ein Neuron hat meist mehrere Eingangsgrößen, welche alle zusammen mit den Gewichten aufsummiert werden. Diese Werte werden zufällig




Abbildung 8: Aufbau eines Neurons [1]

initialisiert und per Training verbessert, somit handelt es sich um einen angelernten Werte, welche durch die Backproagation(Fehlerrückführung) verbessert werden.

Schwellwert aka bias Auf dieses Aufsummiertes Ergebniss wird anschließend ein Bias gerechnet, dieser führt zu einem besseren Verhalten beim Trainieren. Bei diesen Werten handelt es sich um angelernte Werte, die per Backpropagation verbessert werden und die Flexibitlität der Netze erhöht.

Aktivierungs Funktion Die Aktivierungsfunktion kann man sich als Schwellwert vorstellen, ab wann das Neuron den Input weiter gibt. Es gibt verschiedene Funktionen, um diesen Schwellwert zu definieren. Je nach Aufgabe des Neuronalen Netze werden andere Aktivierungsfunktionen verwendet. Bei Klassifizierungen werden heute meist ReLu-Layer oder ein Weakly-ReLu Layer benutzt, diese verhindern das Vanishing- bzw. Exploding-gradientproblem beim Trainieren.

Ausgang aka Output Wenn der Schwellwert überschritten wird, wird am Output durchgeschaltet. Dieser Output kann entweder mit einer nen Schicht Neronen verbundne sein oder direkt als Ausgang gesehen werden. Über welchen man anhand von xxxVariablenwerten/Kommawerten die Von Input nach Output nennt sich ein Single-Forward-Pass. Wie hier beschrieben wird, kann ein Netz verschieden viele Layer besitzen mit verschiedenen Anzahlen von Neuronen.

2.3.2 Struktureller Aufbau eines Neuronales Netzes

Wie kann ich Neuronen zusammenbauen usw.

Input Layer

Hidden Layer

Output Layer

2.3.3 Verlustfunktion aka lossfunktion

Die Verlustfunktion stellt ein ausgesuchtes Maß der Diskrepanz zwischen den beobachteten und den vorhergesagten Daten dar. Sie bestimmt die Leistungsfähigkeit des neuronalen Netzes während des Trainings und der Ausführung. Ziel ist es, im laufenden Prozess der Modellanpassung, die Verlustfunktion zu minimieren.

2.3.4 Optimierer alt Gradientenabstieg

Um die Fehlerfunktion zu minimieren wird als Werkzeug der Gradienten Abstieg benutzt. Diese ist nur möglich da ein Künstliches Neuronales Netz aus verketteten differenzierbaren Gewichte der Neuronen(Tensoroperationen) aufgebaut ist, die es erlauben durch anwendung der Kettenregel die Gradientenfunktion zu finden, die den aktuellen Parametern des Datenstapels werte des Gradienten zuordnet. Es gibt auch hier verschiedene Ansätze von Optimierern, welche die genauen Regeln wie der Gradient der Verlustfunktion zu Aktualisierung der Parameter verwendet wird hier könnte Beispielweise den RMSProp-Optimierer, der die trägheit des Gradientenabstiegsverfahren berücksichtigt.

Seite 83 - Deep Learning chollet

2.3.5 Hyperparameter

Als Hyperparameter werden, in Bezug auf KNN's, meist die Anfangsbedingungen bezeichnet. Für diese Hyperparameter gelten keine universellen Werte sondern müssen je

nach Daten und Funktion bzw. künstliches Neuroales Netz speziell angepasst und verändert werden. Deshalb gibt es nur einige Regeln und grobe Abschätzungen in welchen grenzen sich diese Hyperparameter befinden. Zu diesen Hyperparameter gehören folgende:

- **Learningrate**,blabalaa
- **Dropout**
- **Lossfunktion**
- **Optimizer**
- **Model Achitektur**

2.4 Zusammenfassung

3 Stand der Forschung und Technik

3.1 Forschung

3.2 Anwendung

NEAT, HyperNEAT, GLEN

3.3 Zusammenfassung

4 Konzept

4.1 Anforderungsanalyse

4.2 Genetischer Algorithmus

4.2.1 Eltern auswahl

Ranking Selction mit 50 übernahme als Eltern. Zusätzlich werden die besten 4 Eltern ganz übernommen. das die Generationen sich nicht zu sehr ähnlichsind wird hoh mutation bei den Kindern. Zusätzlich werden bei jeder neuen Generation immer ein paar neu und damit zufällige Individuen hinzu gefügt.

Best 50 prozent,heißt aus der oberen hälfte der alten Generation werden alle Induviduen dem Elternpool hinzugefügt. Aus welchen dann zufällig die einzelnen Elternteile ausgewählt werden. Es mssen natürlich nicht immer 50 prozent sein, es kann sich auch um einen anderen Prozentsatz handeln.

4.3 Zusammenfassung

5 Implementierung

5.1 Systemaufbau

5.2 Zusammenfassung

6 Evaluation und Tests

6.1 Einleitung

6.2 Testszenarien

6.3 Evaluation

6.4 Ergebniss und Interpretation

6.5 Zusammenfassung

7 Zusammenfassung und Ausblick

7.1 Einleitung

7.2 Zusammenfassung

7.3 Bedeutung der Arbeit

7.4 Ausblick

Literatur

- [1] T. Rashid. *Neuronale Netze selbst programmieren: Ein verständlicher Einstieg mit Python*. Animals. O'Reilly, 2017.
- [2] Projekt Heike.
- [3] Anupriya Shukla, Hari Pandey, and Deepti Mehrotra. Comparative review of selection techniques in genetic algorithm. 02 2015.
- [4] James Edward Baker. Adaptive selection methods for genetic algorithms. In *Proceedings of an International Conference on Genetic Algorithms and their applications*, pages 101–111. Hillsdale, New Jersey, 1985.
- [5] Gilbert Syswerda. Uniform crossover in genetic algorithms. In *Proceedings of the 3rd International Conference on Genetic Algorithms*, pages 2–9, San Francisco, CA, USA, 1989. Morgan Kaufmann Publishers Inc.
- [6] Dr. Anantkumar Umbarkar and P Sheth. Crossover operators in genetic algorithms: A review. *ICTACT Journal on Soft Computing (Volume: 6 , Issue: 1)*, 6, 10 2015.