

Vorlesung Computational Intelligence:

Teil 3: Künstliche Neuronale Netze

Ralf Mikut, Wilfried Jakob, Markus Reischl

Karlsruher Institut für Technologie, Institut für Automation und angewandte Informatik

E-Mail: ralf.mikut@kit.edu, wilfried.jakob@kit.edu

jeden Donnerstag 14:00-15:30 Uhr, Nusselt-Hörsaal

3 Künstliche Neuronale Netze

3.1 **Vom Biologischen zum Künstlichen Neuronalen Netz**

3.2 Struktur

3.3 Lernverfahren

3.4 Multi-Layer-Perceptron-Netze (MLP-Netze)

3.5 Radial-Basis-Funktions-Netze (RBF-Netze)

3.6 Kohonen-Karten

3.7 Deep Learning & Convolutional Neural Networks


3.8 Kommentare

Biologische Neuronale Netze bestehen aus vielen Neuronen:


- Biene: 10^6 Neuronen, je ca. 10^3 Verbindungen zu Nachbarzellen
 - Mensch: $10^{10} \dots 10^{12}$ Neuronen,
je ca. 10^4 Verbindungen zu Nachbarzellen
 - Funktionsweise des Zusammenwirkens nur teilweise verstanden, viele laufende Arbeiten und Projekte (u.a. Human Brain Project der EU, >1 Mrd €):
 - Wie sehen die anatomischen Strukturen in einem Hirn im Detail wirklich aus (Elektronenmikroskopie)?
 - Was passiert funktionell? Bestimmung z.B. durch
 - Funktionelle Magnetresonanztomographie als indirekte Messung der Durchblutung beim Menschen/bei Tieren
 - elektrisches Kontaktieren einzelner Nervenzellen
 - Lichtscheibenmikroskopie bei genetisch modifizierten Tieren mit Beispielvideo aus [Ahrens 2013])
- Problem: räumliche und/oder zeitliche Auflösung
- Wie kann man die Vorgänge simulieren?


Biologische Nervenzelle

- Dendriten (Eingänge) in räumlicher Nähe zu Synapsen anderer Neuronen
- komplizierte elektrochemische Zusammenhänge
- im Hirn und Rückenmark
- Axone von Motoneuronen koppeln an Muskeln an (extrem lang!)




Bildquelle: Wikipedia



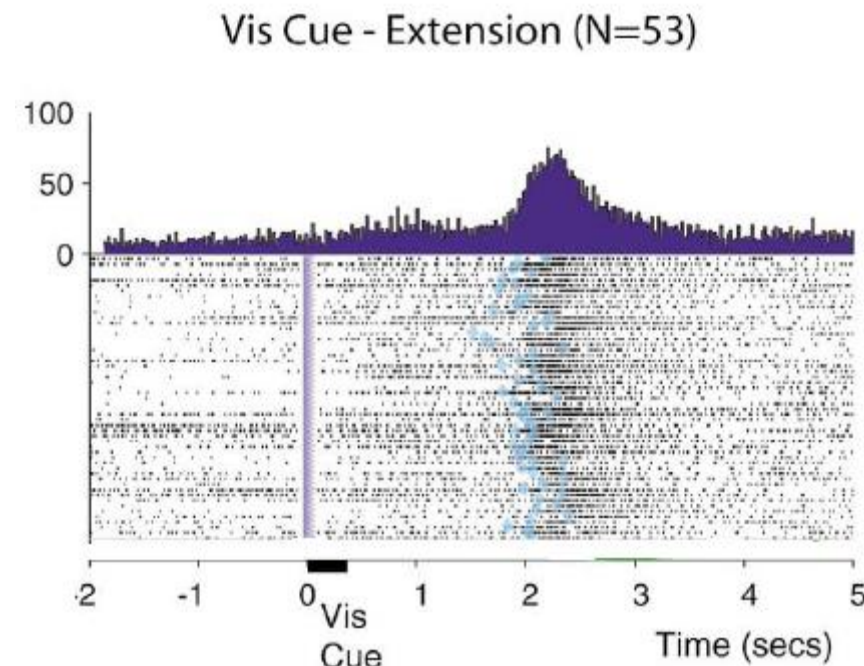


Biologische Aktionspotenziale

- Ausgang (Axon): Spikes (Feuern) nach dem Ja-Nein-Prinzip
- links: Feuern eines Neurons (Spike)
- je stärker die Aktivierung, desto häufiger treten Spikes auf
- rechts: Aktivierung eines Motoneurons nach optischem Reiz in nachfolgenden Versuchen beim Affen





Bildquelle: Wikipedia

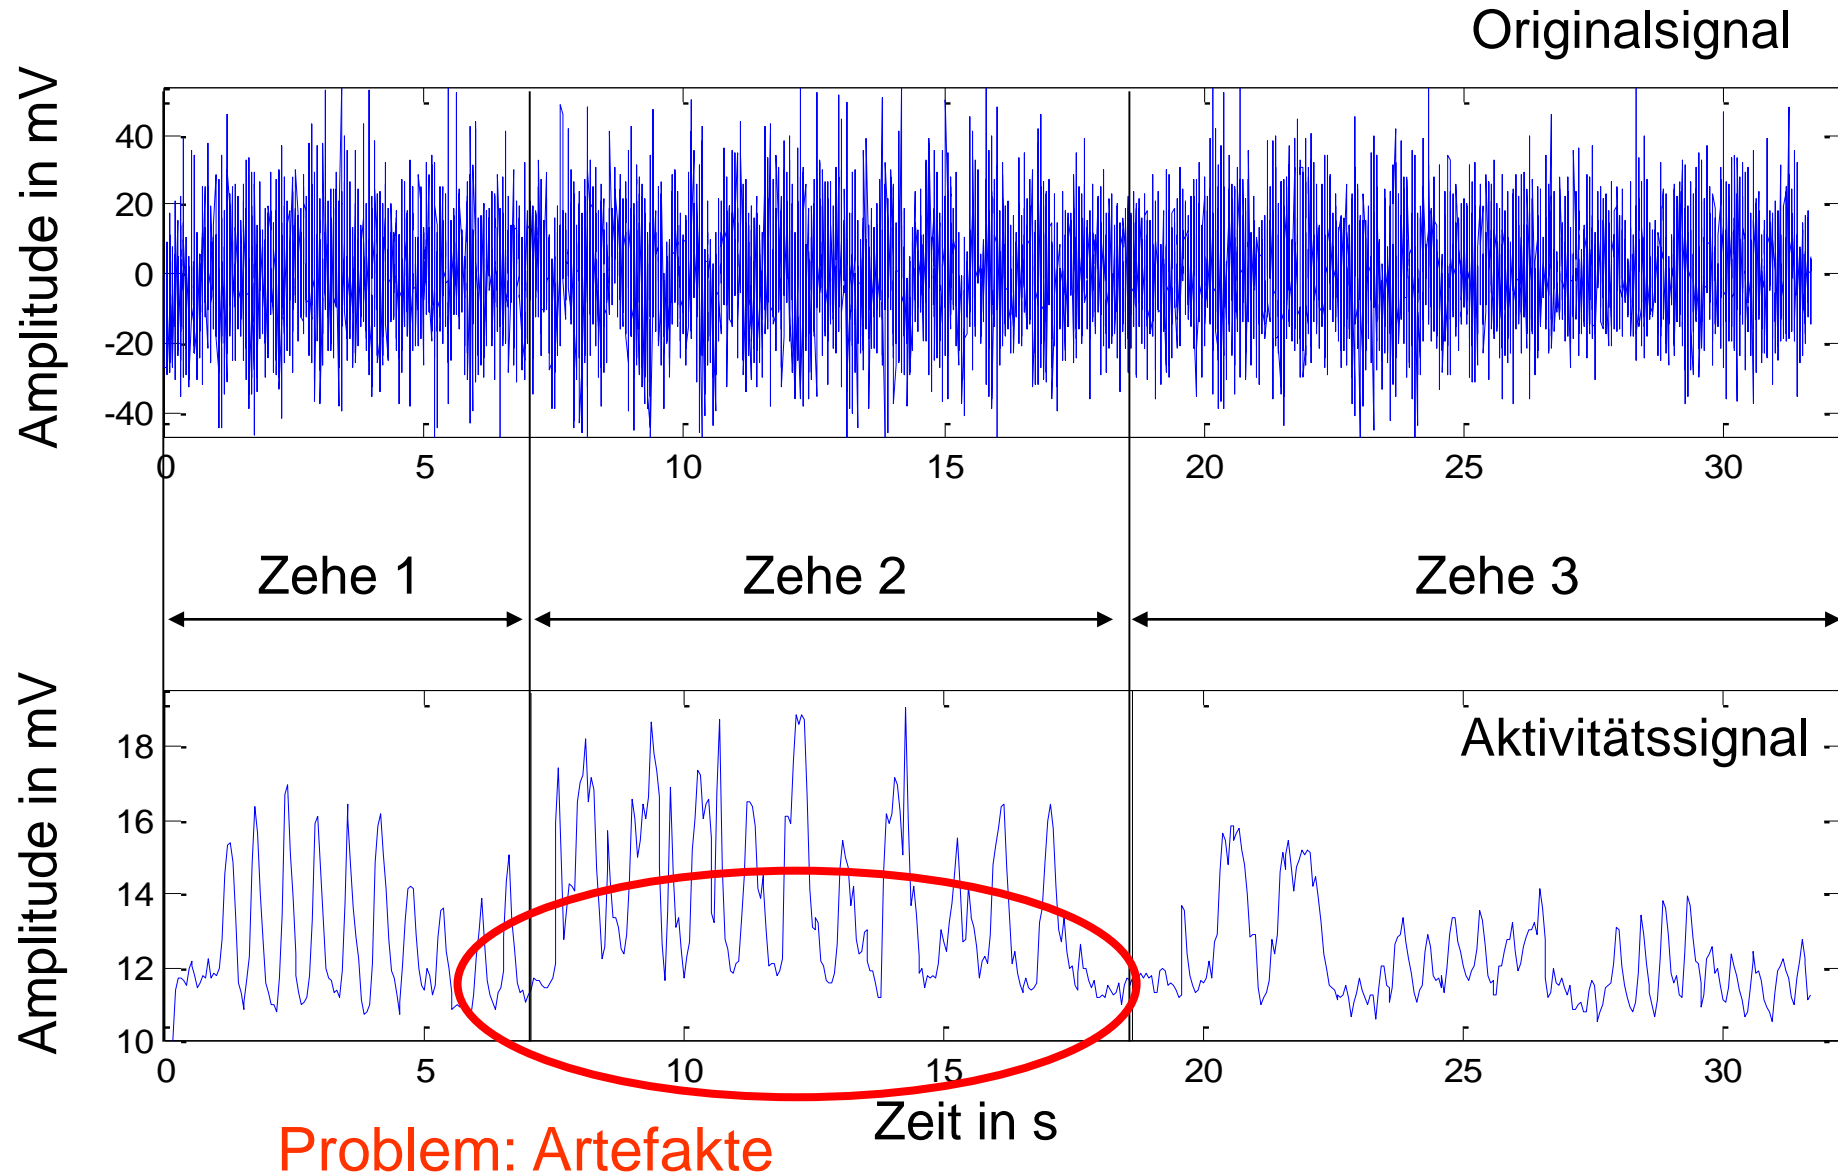



Fetz, E.; Perlmutter, S.; Prut, Y.; Seki, K. & Votaw, S. Roles of Primate Spinal Interneurons in Preparation and Execution of Voluntary Hand Movement *Brain Research Reviews*, **2002**, 40, 53-65

Messung mit Elektroneurographie (ENG)




Beispiel für ENG-Zeitreihen



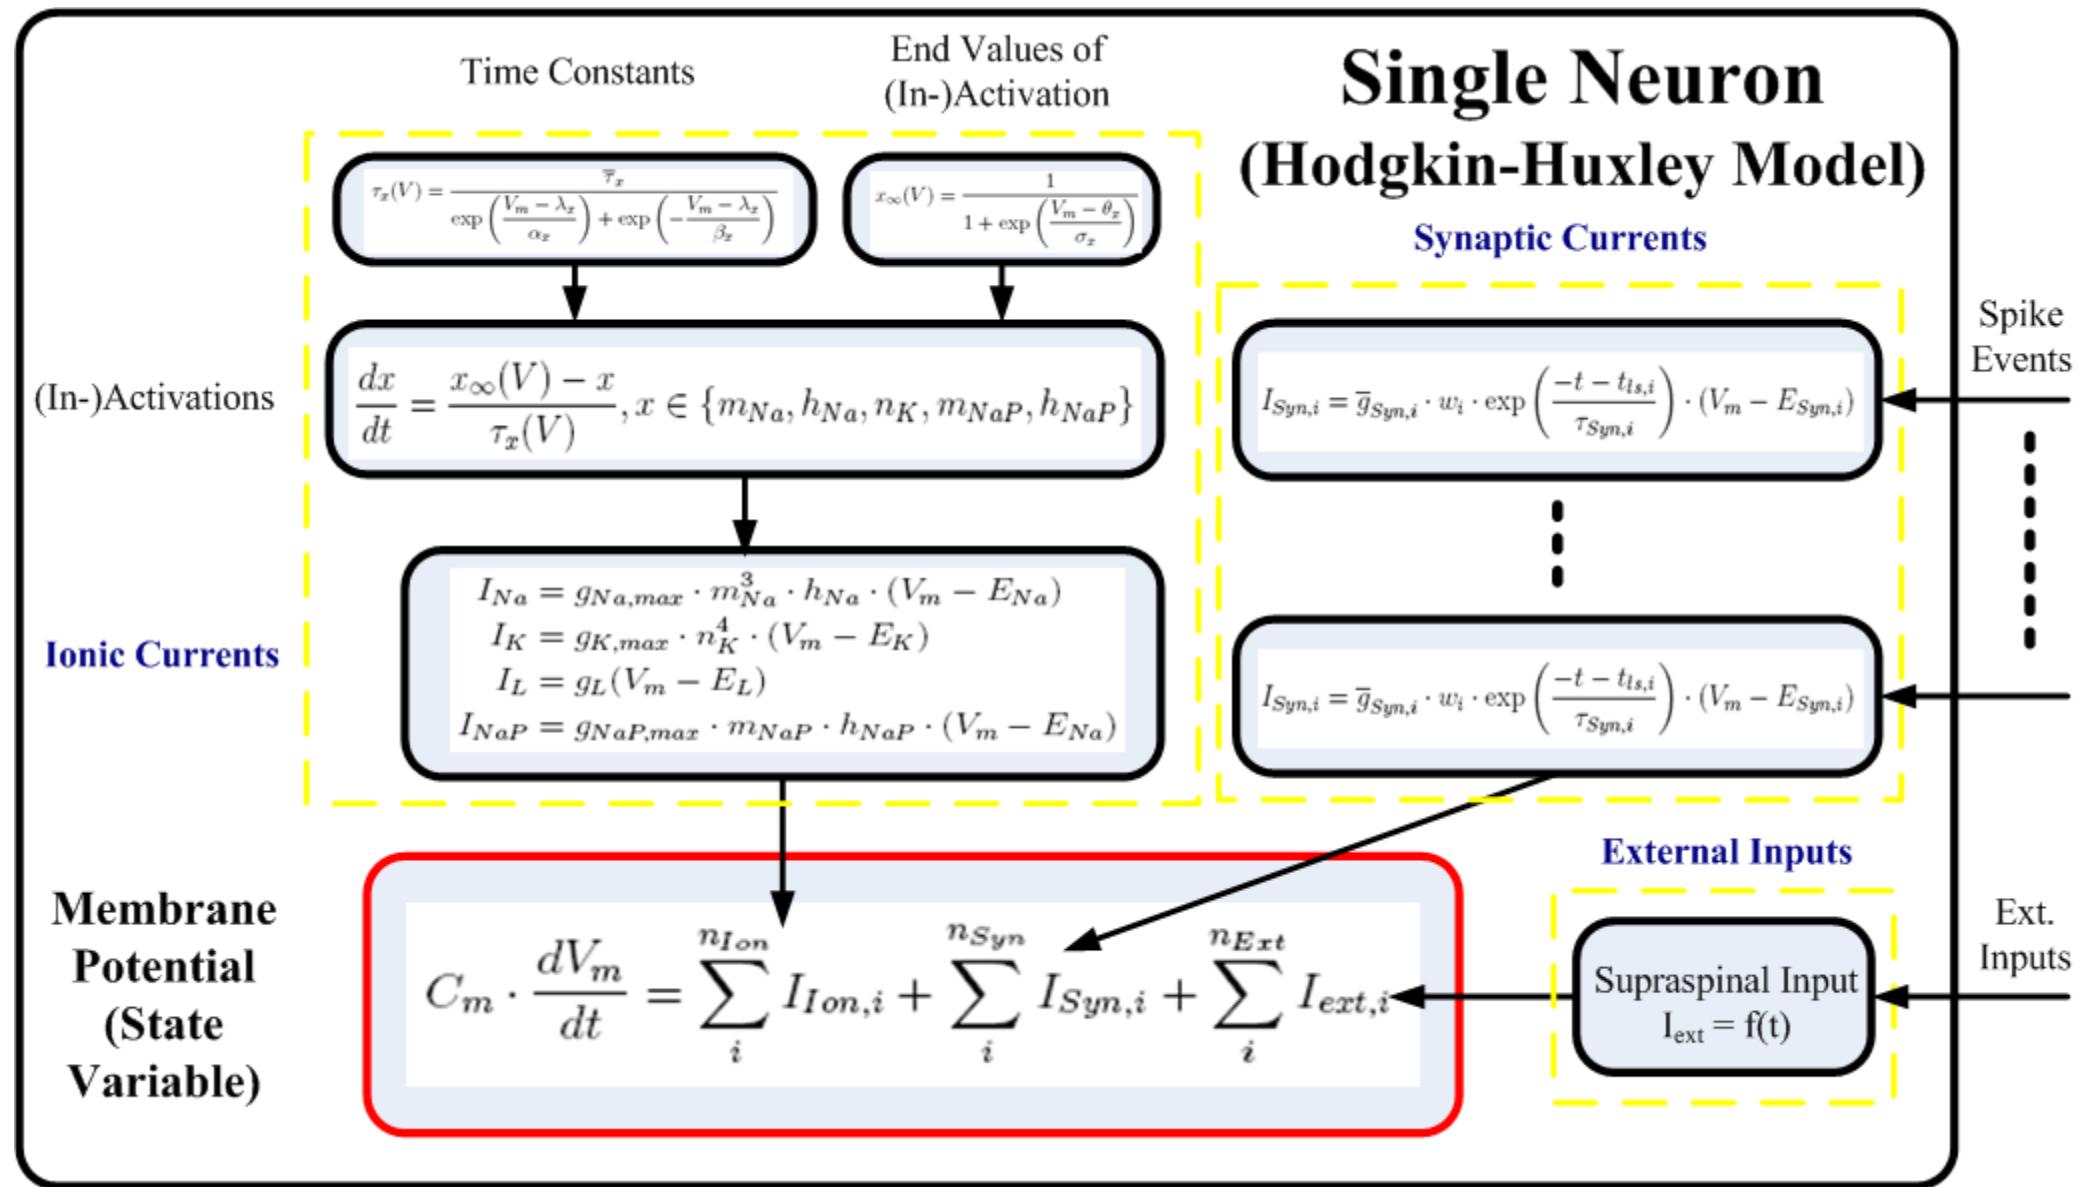


Zehe 1: starke Aktivität



Zehe 2: starke Aktivität

Hodgkin-Huxley-Modell (biologisch realistisch)




Internal State Variable: V_m

Output: Last Spike Time (Spike Events)


Verschaltung von „biologischen“ Neuronen

Schematische Darstellungen
zweier Neuronen
(Gray's Anatomy
of the Human Body von 1918,
Zelle aus dem Kleinhirn):

- a - Axon
(Ausgang des Neurons)
- d - Dendriten
(Eingänge)
- b – Synapsen (Kopplung des
Ausgangs mit anderen
Neuronen bzw. Muskeln)




- Aufnahme mit Lichtscheibenmikroskopie beim Zebrafärbling, siehe Videos in [Ahrens13]
- Genetische Modifikation zum Messen von Calcium; einzelne Zellen sichtbar
- Räumliche Auflösung im Mikrometerbereich
- Zeitliche Auflösung 0.7 Hz bei Aufnahme des gesamten Hirns
- Videos ohne externe Reize, weitere Arbeiten für Schwimmbewegungen usw. in [Freeman14]



[Ahrens13] Ahrens, M. B.; Orger, M. B.; Robson, D. N.; Li, J. M. & Keller, P. J.: Whole-brain Functional Imaging at Cellular Resolution using Light-Sheet Microscopy. *Nature Methods*, Nature Publishing Group, **2013**, 10, 413-420

[Freeman14] Freeman, J.; Vladimirov, N. et al.: Mapping Brain Activity at Scale with Cluster Computing. *Nature Methods*, Nature Publishing Group, **2014**, 11, 941-950


Brain Computer Interfaces



University of Pittsburgh



University of Pittsburgh



University of Stanford

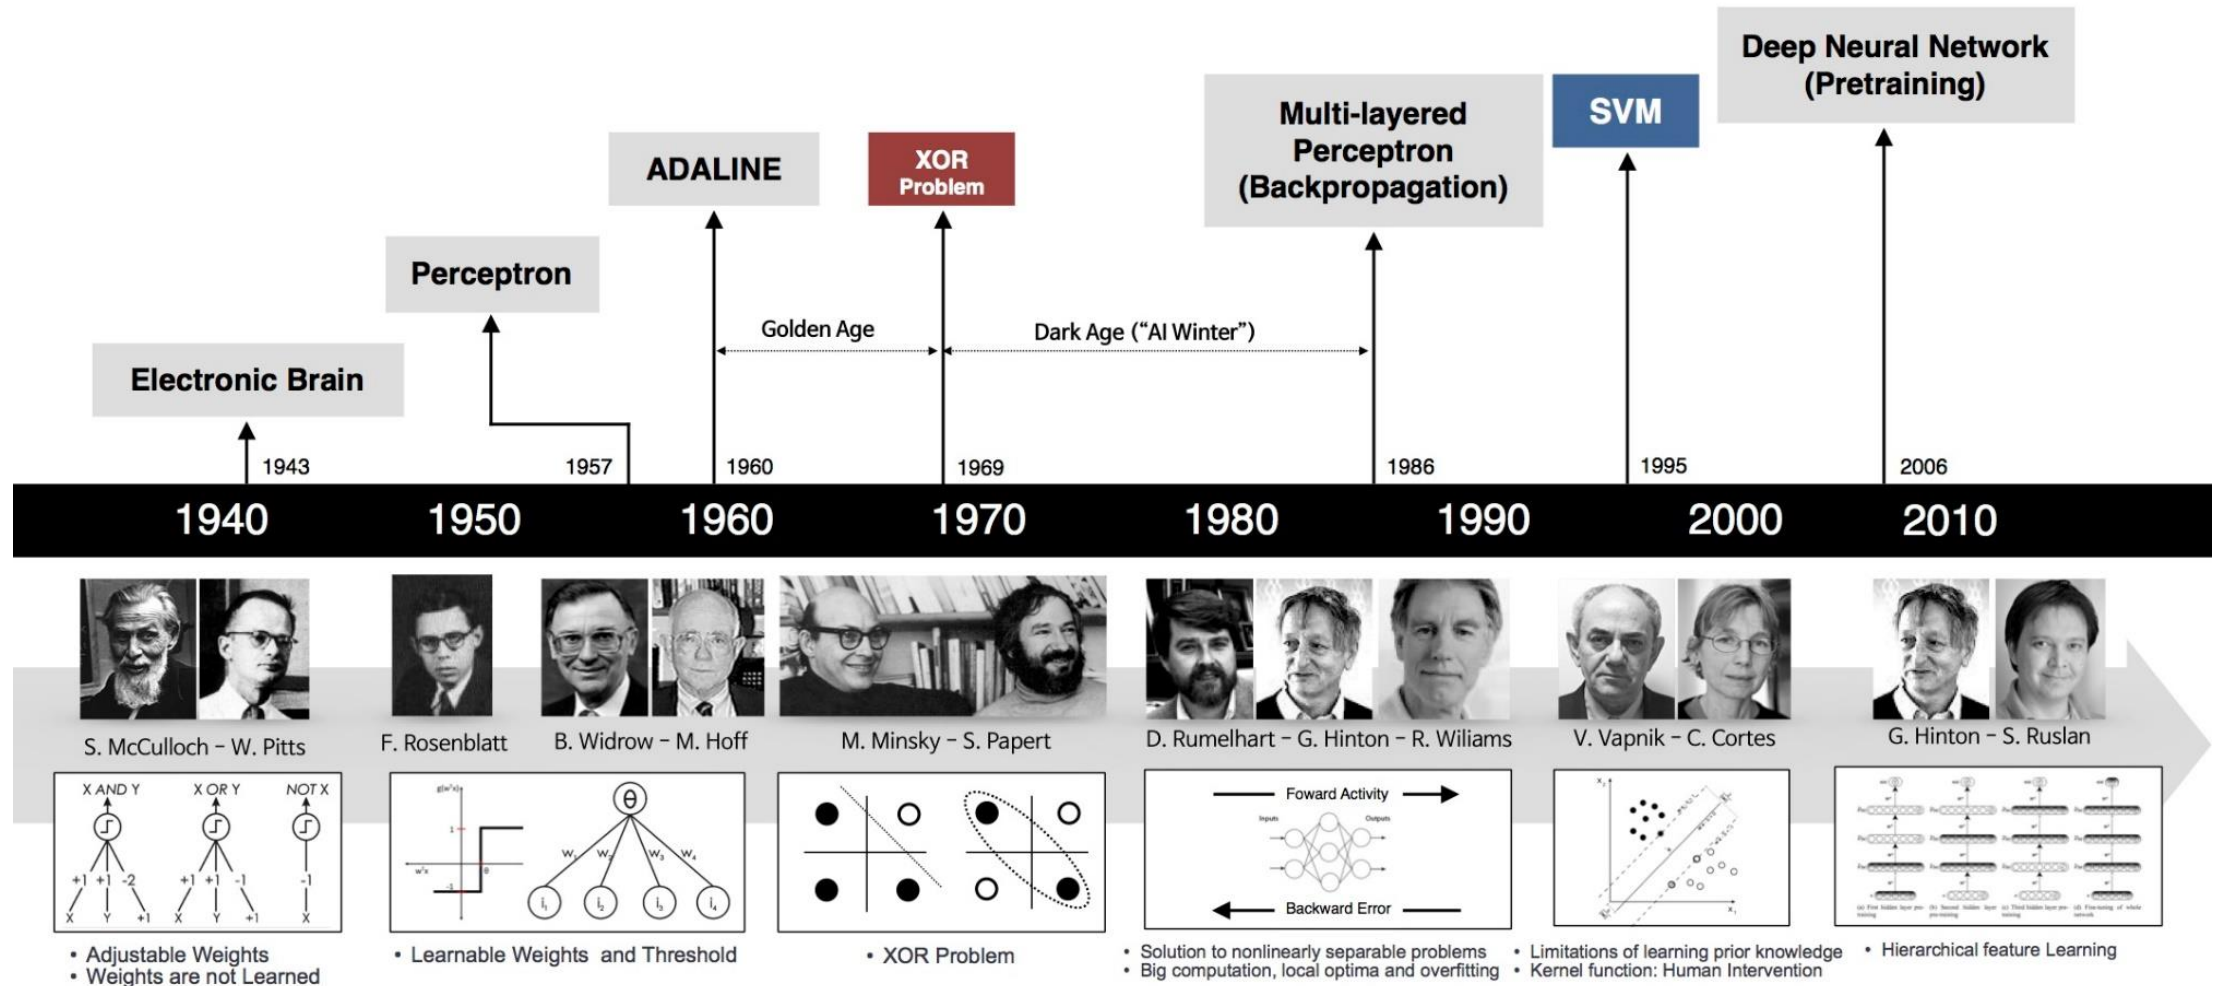
- + Visionär
- Kein Benefit im Vergleich zu herkömmlichen Steuerungen
- Geringe Akzeptanz (Operation, Kosmetik)
- Entzündungen
- Keine stabile Steuerung sichergestellt

- 3 Künstliche Neuronale Netze
 - 3.1 Vom Biologischen zum Künstlichen Neuronalen Netz
 - 3.2 Struktur**
 - 3.3 Lernverfahren
 - 3.4 Multi-Layer-Perceptron-Netze (MLP-Netze)
 - 3.5 Radial-Basis-Funktions-Netze (RBF-Netze)
 - 3.6 Kohonen-Karten
 - 3.7 Deep Learning & Convolutional Neural Networks
 - 3.8 Kommentare

- Extreme Vereinfachung biologischer neuronaler Netze!
- Typisches künstliches neuronales Netz:
 - weniger Neuronen, meist 10...1000
 - Verzicht auf die Modellierung von Spikes
- Nutzung:
 - Lernen und Verallgemeinern anhand von Beispielen
 - Erkennen und Vervollständigen komplizierter Muster
 - Verständnis biologischer neuronaler Netze durch Simulation und Analyse (nicht in dieser Vorlesung)

- Definition: Künstliche Neuronale Netze (KNN) sind stark vereinfachte technische Realisierungen zur Modellierung der Informationsverarbeitung im Gehirn und im Nervensystem.
- Kennzeichen sind lernfähige, dezentrale, parallele Strukturen aus einfachen Elementen (Prozesseinheiten (PE) bzw. Neuronen)
- Begriffe in dieser Vorlesung orientieren sich an
VDI/VDE-Richtlinie 3550 Blatt 1 Computational Intelligence - Künstliche Neuronale Netze in der Automatisierungstechnik - Begriffe und Definitionen
- engl. Artificial Neural Networks (ANN)

Geschichte Neuronaler Netze




Quelle: https://beamandrew.github.io/deeplearning/2017/02/23/deep_learning_101_part1.html

Parallelentwicklungen:

- RBF-Netze (M.J.D. Powell, D. Broomhead, D. Lowe, ab 1987/88)
- Kohonen-Karten bzw. Self-Organizing Maps (T. Kohonen, ab 1982)


Aufbau eines typischen "künstlichen" Neurons

- Wie beim biologischen Neuron:
 - mehrere Eingänge
 - Eingänge wirken unterschiedlich auf das Neuron (hemmend, stimulierend)
 - interner Zustand (Potenzial)
 - ein Ausgang
- Bezeichner:
 - Eingangsgrößen x_i , $i=1, \dots, s$
 - Gewichte w_i zur Beschreibung der skalaren Kopplungsstärke der i -ten Eingangsgröße zum Neuron
 - Zustand z des Neurons (skalar!)
 - Aktivierungsfunktion $f(z)$
 - Ausgangsgröße y des Neurons
- kompliziertere Strukturen existieren, sind aber nicht sehr gebräuchlich



Bestimmung des Zustands

- dient zum Zusammenfassen der Eingänge eines Neurons
- bestimmt, ob ein Neuron für eine bestimmte Eingangskonstellation "zuständig" (aktiviert) wird oder nicht, z.T. auch mit der Möglichkeit von Hemmungen (negative Gewichte von w_i)
- Beispiele:



$$z(\mathbf{x}, \mathbf{w}) = \mathbf{w}^T \cdot \mathbf{x} + w_0 \quad (\text{gewichtete Summe mit Absolutterm})$$

$$z(\mathbf{x}, \mathbf{w}) = e^{-w_0 \cdot (\mathbf{x} - \mathbf{w})^T (\mathbf{x} - \mathbf{w})} \quad (\text{RBF: Radiale Basisfunktion})$$

$$z(\mathbf{x}, \mathbf{w}) = e^{-d^2(\mathbf{x}, \mathbf{w})} \quad (\text{beliebige Distanz})$$

$$z(\mathbf{x}) = \operatorname{argmax}_i x_i \quad (\text{Wettbewerbslernen})$$

- "Zustand" ist für alle hier genannten Funktionen statisch

Aktivierungsfunktionen (1)

- Aktivierungsfunktion $f(z)$ modelliert die Erregungsschwelle des biologischen Neurons
- Einfachste Aktivierungsfunktion ist Schwellwert, aber andere Funktionen werden häufiger genutzt:


$$f(z) = \begin{cases} 1 & \text{für } z \geq 0 \\ 0 & \text{sonst} \end{cases} \quad (\text{Schwellwert})$$

$$f(z) = \begin{cases} z & \text{für } z \geq 0 \\ 0 & \text{sonst} \end{cases} \quad (\text{ReLu: Rectified Linear Unit})$$

$$f(z) = z \quad (\text{Lineare Aktivierungsfunktion})$$

$$f(z) = \frac{2}{1 + e^{-2z}} - 1 \quad (\text{Tansig-Funktion})$$

$$f(z) = \frac{1}{1 + e^{-z}} \quad (\text{Sigmoid-Funktion})$$



- Bestimmung des Zustands und Aktivierungsfunktion können auch in einer Funktion zusammengefasst werden

Aktivierungsfunktionen (2)



Für einige Lernverfahren ist es wichtig, dass die Aktivierungsfunktion stetig nach z differenzierbar ist.

$$\frac{df}{dz} = 1 \quad (\text{Lineare Aktivierungsfunktion})$$

$$\frac{df}{dz} = 1 - f^2(z) \quad (\text{Tansig-Funktion})$$


$$\frac{df}{dz} = f(z) \cdot (1 - f(z)) \quad (\text{Sigmoid-Funktion})$$

- Sinnvoll:
Tansig- oder Sigmoid-Funktion
("Weiche Schwellwerte")
- Logsig-Funktion ist Synonym zu Sigmoid-Funktion



Hauptunterschiede zum biologischen Neuron

- Ein- und Ausgangsgrößen sind keine Zeitreihen von Spikes, sondern statisch (Äquivalent: höhere Werte, wenn Neuron öfters "feuert")
- Zustand ist statisch, damit kein Zustand im Sinne einer Differenzialgleichung oder Differenzengleichung mehr
- Neuron hat folglich statisches Ein-Ausgangs-Verhalten






Neuronen sind oftmals in Schichten strukturiert:

- Eingabeschicht:
zugehörige Neuronen haben direkte Verbindungen aus der Umgebung in das Netz hinein
- Verdeckte Schicht (Synonym: verborgene Schicht, Hidden-Schicht):
zugehörige Neuronen haben keine direkte Verbindung zur Umgebung
- Ausgabeschicht:
zugehörige Neuronen haben direkte Verbindungen in Richtung der Umgebung

Verbindungsstrukturen (2)

- **vorwärtsgerichtet (feedforward):** Die Schichten werden in Vorwärtsrichtung miteinander verbunden. Die Information breitet sich von der Eingabeschicht durch die verdeckte(n) Schicht(en) aus und führt zum Ergebnis in der Ausgabeschicht.
- **laterale Verbindungen:** Innerhalb einer Schicht existieren Verbindungen zwischen den einzelnen Prozesseinheiten (PE).
- **rückgekoppelt (feedback):** Der Ausgang einer PE wird auf den eigenen Eingang zurückgeführt oder Ausgänge von PE werden über eine oder mehrere Schichten zurückgekoppelt



Bemerkungen:


- Vorwärtsgerichtete Netze mit statischen Neuronen haben statisches Ein-Ausgangs-Verhalten.
- Laterale und rückgekoppelte Verbindungen führen oft zu zeitlichen Abhängigkeiten (meist als Zeitverzögerung um einen Abtastschritt), Netze werden dann als rekurrente Netze bezeichnet und haben dynamisches Ein-Ausgangs-Verhalten.
- Rückkopplungen sind sowohl im Netz als auch außerhalb des Netzes (Ausgangsgrößen koppeln auf Eingangsgrößen zurück) möglich!

- 3 Künstliche Neuronale Netze
 - 3.1 Vom Biologischen zum Künstlichen Neuronalen Netz
 - 3.2 Struktur
 - 3.3 Lernverfahren**
 - 3.4 Multi-Layer-Perceptron-Netze (MLP-Netze)
 - 3.5 Radial-Basis-Funktions-Netze (RBF-Netze)
 - 3.6 Kohonen-Karten
 - 3.7 Deep Learning & Convolutional Neural Networks
 - 3.8 Kommentare

- Entwurf (Synonyme: Lernphase, Trainingsphase, Entwurfsphase)
 - Festlegung von Struktur und Parametern anhand eines Lerndatensatzes
 - Struktur wird oft manuell oder mit einem geeigneten Optimierungsverfahren (z.B. Evolutionäre Algorithmen) bestimmt
 - Parametersuche mit auf den Typ des Künstlichen Neuronalen Netzes zugeschnittenen Lerngesetzen
- Anwendung (Synonyme: Arbeitsphase, Anwendungsphase)
 - Künstliches Neuronales Netz bekommt unbekannte Eingangsgrößen und berechnet eine Ausgangsgröße
 - Struktur und Parameter werden dabei meist nicht mehr verändert
 - u.U. auch gelegentlicher neuer Entwurf (Adaption) während der Anwendung möglich, aber in der Praxis selten eingesetzt (riskant!)

Notwendige Strukturentscheidungen

- Wahl der Eingangsgrößen eines Systems (Wieviele? Welche?)
- Wahl der Ausgangsgrößen eines Systems (Wieviele? Welche?)
- Verbindungsstruktur
- Anzahl verdeckter Schichten
- Anzahl der Neuronen in der verdeckten Schicht
- Art der Aktivierungsfunktion
- Funktion zur Bestimmung des Zustands



Strukturentscheidungen bestimmen Typ des Neuronalen Netzes, z.B.

Multi-Layer-Perceptron (MLP):

feedforward, mindestens eine verdeckte Schicht, gewichtete Summe mit Absolutterm, Tansig- oder Sigmoid-Funktion als Aktivierungsfunktion, ...

- Festlegung Struktur:
 - Kompromiss zwischen Anpassungsfähigkeit an das Ziel (viele Parameter) und Generalisierungsfähigkeit bezüglich Störunterdrückung und gutem Approximationsverhalten (wenige Parameter):
 - zu einfach: Unteranpassung (Underfitting)
 - zu kompliziert: Überanpassung (Overfitting)
- Veränderung der Parameter (Gewichte) anhand des Lerndatensatzes und der Lerngesetze, meist ausgehend von zufälligen Startparametern
- Lerndatensatz:
 - Beispiele ("Datentupel"), die das Problem möglichst vollständig abdecken
 - N Datentupel mit bekannten Eingangsgrößen $\mathbf{x}[n]$, $n=1, \dots, N$
 - optional: N Datentupel mit bekannten Ausgangsgrößen $\mathbf{y}[n]$, $n=1, \dots, N$
 - Ein- und Ausgangsgrößen in der Regel reellwertig
- Lernziel (Gütekriterium):
Abbruch wenn Lernziel erreicht oder keine Verbesserung mehr eintritt
- u.U. Test auf Güte mit zusätzlichem Testdatensatz
- Ergebnis: Struktur, Parameter

Typen von Lernverfahren

- Überwachtes Lernen ("Lernen **mit** Lehrer"):
Ausgangsgröße für Lerndatensatz bekannt, z.B.
 - Backpropagation-Algorithmus
 - Levenberg-Marquardt-Algorithmus
- Reinforcement Learning:
Qualitätsbewertung einer Ausgangsgröße (Lob/Tadel)
- Unüberwachtes oder Selbstorganisiertes Lernen ("Lernen **ohne** Lehrer"):
Ausgangsgröße für Lerndatensatz unbekannt, z.B.
 - Hebb'sches Lernen
 - Lernverfahren für Kohonen-Karten
- Teilüberwachtes Lernen:
Ausgangsgröße ist nur für einen Teil der Datentupel im Lerndatensatz bekannt

Selbstorganisiertes Lernen: Hebb'sche Regel

- Das erste Lerngesetz wurde 1949 von HEBB für das biologische Modell formuliert:

„Verbindungen zwischen Neuronen werden dann verstärkt werden, wenn die Neuronen gleichzeitig aktiv sind.“

- mathematische Realisierung für jedes Gewicht w_{ij} , das von Neuron j zu Neuron i verbindet (Doppel-Index i,j jetzt notwendig, um beide Neuronen eindeutig zu adressieren):

$$w_{i,j}[k+1] = w_{i,j}[k] + \Delta w_{i,j}[k] \text{ mit}$$

Lernfaktor $\rho > 0$

$$\Delta w_{i,j}[k] = f(y_i[k], y_j[k]), \text{ z. B. } \Delta w_{i,j}[k] = \rho \cdot y_i[k] \cdot y_j[k]$$

- Anlehnung an biologische neuronale Netze
- "Lernen durch Verstärkung"
- keine Ausgangsgröße des Netzes im Lerndatensatz notwendig