


Vorlesung Computational Intelligence

Teil 4: Evolutionäre und Memetische Algorithmen

4.8 Memetische Algorithmen

Ralf Mikut, Wilfried Jakob, Markus Reischl

Institut für Automation und angewandte Informatik (IAI) / Campus Nord



4.8 Memetische Algorithmen

Übersicht


- Motivation
- Formen der EA-Hybridisierung
- Klassische Memetische Algorithmen
 - Gestaltungsmöglichkeiten
 - Pseudocode
 - Lohnt der Aufwand?
- Ausblick: Adaptive Multimemetische Algorithmen
- Zusammenfassung
- Beispiel einer Pareto-Optimierung mit dem NSGA-II und hybriden Varianten

Memetische Algorithmen – Motivation

Wo haben die Verfahren ihre Stärken und Schwächen?




	Konvergenz (in Optimumnähe)	Globalität der Suche
Evolutionäre Algorithmen		
Lokale Suchverfahren (LSV)		



Mmmh,
da müsste sich doch
etwas machen lassen

...

... vielleicht kommt man
mit Zusammenarbeit
weiter?



Memetische Algorithmen – Motivation

Idee: Kombination von **Evolutionärem Algorithmus** und **lokaler Suche**
→ **Hybrider Evolutionärer Algorithmus**, **Memetischer Algorithmus**

Ziele:

- **Bewahrung der positiven Eigenschaften Evolutionärer Algorithmen:**
 - **globale Natur der Suche**
 - **generelle Anwendbarkeit** (bei allgemeinen lokalen Suchverfahren)
 - **hohe Konvergenzsicherheit** (keine Garantie!)
- **Verbesserung der Schwachpunkte:**
 - **geringe Konvergenzgeschwindigkeit**
(insbesondere mehr oder weniger in der Nähe eines (Sub-)Optimums)

**Der Versuch, das Beste aus beiden Welten zu kombinieren,
von den Evolutionären Algorithmen und
von den lokalen Suchverfahren**

Arten der Hybridisierung (1):

1. Initialisierung der Startpopulation

- Idee: ► Start der evolutionären Suche mit zulässigen bis brauchbaren Lösungen
- Einbringung von Vorwissen

Kann gute Ergebnisse erbringen und die Suche beschleunigen.

Maximal 20% der Population derart verbessern! *Warum?* 

2. Nachoptimierung der EA-Ergebnisse

- Idee: ► Zielgerichtete Verbesserung der EA-Resultate
- Kompensierung der Konvergenzschwäche der EA

Bringt meistens nur geringe Verbesserungen,
z.B. wegen der Verbesserung nur mäßig guter Suboptima,
weil der EA bei Abbruch keine Lösungen im Attraktionsgebiet guter Suboptima oder
des globalen Optimums gefunden hat.

Arten der Hybridisierung (2):

3. Verbesserung der EA-Nachkommen

- Idee: ► LSV-Unterstützung während des gesamten Evolutionsprozesses
► Aus EA-Sicht werden nur noch die „Bergspitzen“ durchsucht.

Liefert je nach verwendetem lokalen Verfahren sehr gute Ergebnisse.

4. Aufgabenteilung

- Idee: ► Zerlegung der Aufgabe in zwei (oder mehrere) Teile
► Bearbeitung der einzelnen Teile durch
 - den EA
 - eine andere (Meta-)Heuristik
 - ein aufgabenbezogenes Verfahren
 - ...
► Keine „Zusammenarbeit“ der Verfahren
► Jedes Verfahren sieht nur „seine“ Teilaufgabe

Sehr anwendungsspezifisch und damit aufwändig

MA – Klassische MA

Memetische Algorithmen (MA):

Erweiterung des EA-Paradigmas der EA um die **kulturelle Evolution**:

- Erwerb und Entwicklung von „Wissen“
 - EA: **Verbesserung der Nachkommen** (Kennzeichen eines MA)
- Weitergabe von „Wissen“ an die nächste Generation
 - EA: Vererbung der Verbesserung

Memetische Algorithmen entsprechen damit der 3. Hybridisierungsart.

Was kann dem Wissenserwerb beim EA entsprechen ?

- **Lokale Suchverfahren (LSV)** (local hill climber)
 - anwendungsneutrale Verfahren (z.B. alle direkten Verfahren, s. Kap. 4.2)
 - anwendungsspezifische Verfahren (z.B. alle indirekten Verfahren, s. Kap. 4.2)
- **Heuristiken**
 - basierend auf spezifischem Anwendungswissen (→ spezifisch)
 - basierend auf Wissen über ein Anwendungsgebiet (→ allgemeiner)
- **Andere (lokale) Optimierungsverfahren**

MA – Klassische MA

Begriff des **Mems**: Elementare kulturelle Einheit, die sich entwickeln und verbreiten kann (umstrittene Theorie von Dawkins).

Der Begriff der Memetischen Algorithmen versucht, die Metapher der **kulturellen Evolution** der Gedankenwelt der EA hinzuzufügen.

Als **Meme** (englisch für Mem) werden auch häufig die im MA verwendeten **Heuristiken** oder **lokalen Suchverfahren** bezeichnet.

Andere Bezeichnungen für Memetische Algorithmen:

- Hybrid Evolutionary Algorithms
- Baldwinian Evolutionary Algorithms
- Lamarckian Evolutionary Algorithms
- Cultural Algorithms
- Genetic Local Search

Generelle Gestaltungsmöglichkeiten Memetischer Algorithmen:

1. Auswahl eines Verfahrens zur lokalen Suche
Einfach, ungenau und schnell oder aufwändiger, präziser und langsamer?
Allgemein oder anwendungsspezifisch?
2. Anpassung des Genotyps oder nicht (Lamarcksche vs. Baldwin-Evolution)?
Risiko einer zu einheitlichen Population bei Lamarckscher Evolution,
Risiko vorzeitiger Konvergenz gegen Verlust von Information.
3. Wie werden die Nachkommen zur LSV-Verbesserung ausgewählt?
Per *Zufall oder* gemäß *Fitness*?
4. Wie viel Nachkommen sollen verbessert werden?
Frage von *Aufwand* u. *Nutzen* und der *Balance zwischen globaler und lokaler Suche*
5. Wie genau soll die lokale Suche sein?
Frage von *Aufwand* u. *Nutzen* und der *Balance zwischen globaler und lokaler Suche*

Lamarcksche Evolution oder Baldwin-Evolution?

- Genotypische Anpassung an die gefundene Verbesserung (Lamarck)
oder
- nur Übernahme der besseren Fitness (Baldwin)?

Warum sollte man die besseren Werte der Entscheidungsvariablen einfach „vergessen“?



Da Nachbarschaftsmodelle die genotypische Diversität länger bewahren, kann auf den Baldwin-Effekt verzichtet werden (eigene Untersuchungen).

→ Wir verwenden im IAI daher als Diffusionsmodell den Ring und Lamarcksche Evolution

Pseudocode des verwendeten Memetischen Algorithmus: (*memetischer Teil kursiv*)

Initialisierung und Bewertung der Startpopulation

REPEAT (Generationen-Schleife)

FOR alle Individuen der Population

Wähle Partner rankingbasiert

FOR alle Gruppen genetischer Operatoren

Erzeuge Nachkomme(n) und bewerte es oder sie

*Verbessere alle/einige/den besten Nachkommen durch lokale Suche
Passe den besten Nachkommen genotypisch an*

Akzeptanz oder Zurückweisung des besten Nachkommen

UNTIL Abbruchkriterium erfüllt (Zeit , Qualität, Stagnation, ...)

Liefere bestes Individuum (und weitere, falls vorgegeben) als Ergebnis

Allgemein: Es kann auch
Paarungen ohne
LSV-Anwendung geben!

MA – Klassische MA – Lohnt der Aufwand?

Lohnt der Aufwand der LSV-Suche den Nutzen? (1):

Aufgaben:

- Vergleich alternativer Verfahren:
 - reiner EA, hier GLEAM
 - MA mit dem Rosenbrock-Verfahren (**SMA-R**, Simple Memetic Algorithm)
 - MA mit dem Complex-Algorithmus (**SMA-C**)
- Vergleich verschiedener Parametrierungen:
 - verschiedene Populationsgrößen
 - verschiedene Abbruchschranken für die LSVs
 - Verbesserung aller Nachkommen oder nur des Besten
 - Lamarcksche oder Baldwin Evolution (Anpassung des Genotyps oder nicht)
- EAs und MAs sind stochastische Verfahren.
Daher sind viele Läufe pro Verfahren und Parametrierung erforderlich.
 - Vergleiche basieren auf den Mittelwerten von je 100 Läufen
 - Bei geringen Unterschieden statistische Analyse erforderlich!
(Signifikanz der Unterschiede, Vergleich der Konfidenzintervalle, t-Test, ANOVA, ...)

siehe auch Kap. 4.2,
Folien 19 und 20

MA – Klassische MA – Lohnt der Aufwand?

Lohnt der Aufwand der LSV-Suche den Nutzen? (2):

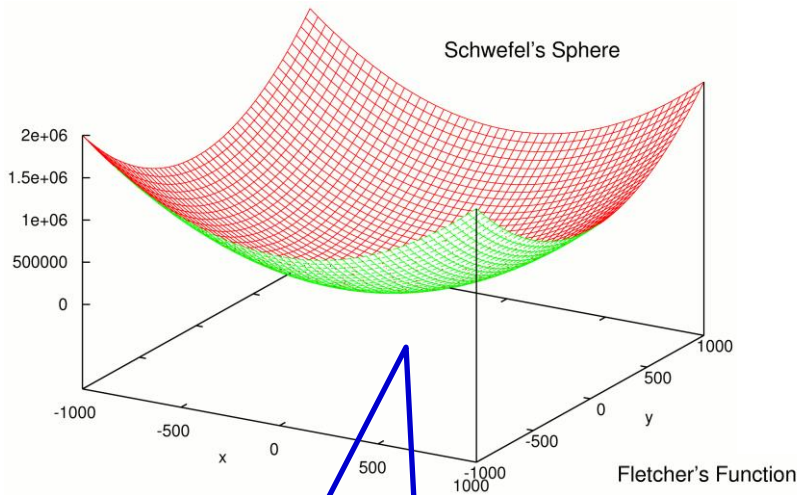
- Vergleich an Hand von **Testfällen**,
 - die ein möglichst breites Anwendungsspektrum abdecken
 - deren Lösungen bekannt sind (zumindest eine erreichbare Qualität)
 - die sich (vergleichsweise) schnell berechnen lassen
 - deren Dimensionen skalierbar sind (wünschenswerte Eigenschaft)
- Neben Testfunktionen sind geeignete **reale Anwendungen** sinnvoll. Hier:
 - Design-Optimierung eines mikro-optischen Bauteils
 - Scheduling mit Nebenbedingungen (Bestimmung geeigneter Startzeiten)
- Verglichen wird der Aufwand (Evaluationen) zur Erreichung einer vorgegebenen Lösungsqualität.

Alternativ könnte man auch die erreichte Lösungsqualität bei gegebenem Aufwand vergleichen.

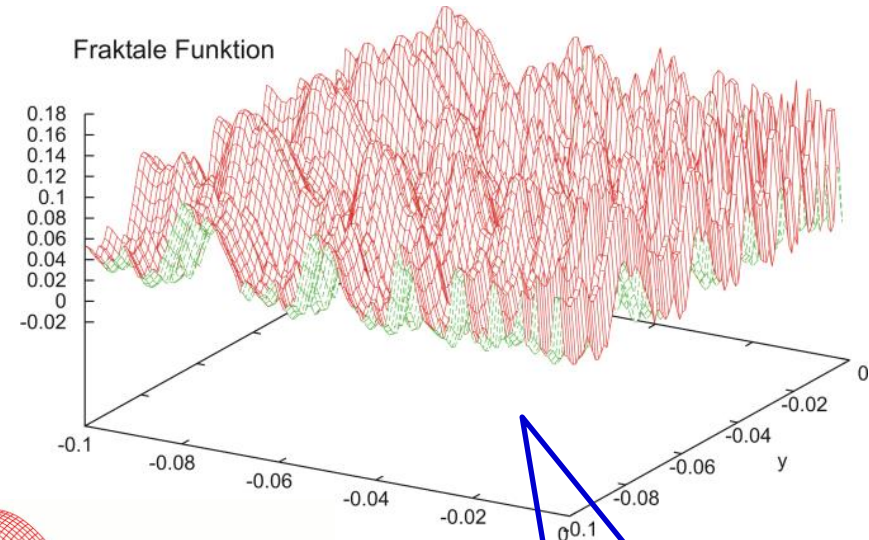
MA – Klassische MA – Lohnt der Aufwand?

Lohnt der Aufwand der LSV-Suche den Nutzen? (3):


Testfunktionen:



Wegen großen Wertebereichen $[-10^{10}, 10^{10}]$ extrem flach im Minimum!



Abbruch bei einer erreichbaren Lösungsqualität



Wird mit zunehmender Dimensionalität schwieriger!

MA – Klassische MA – Lohnt der Aufwand?

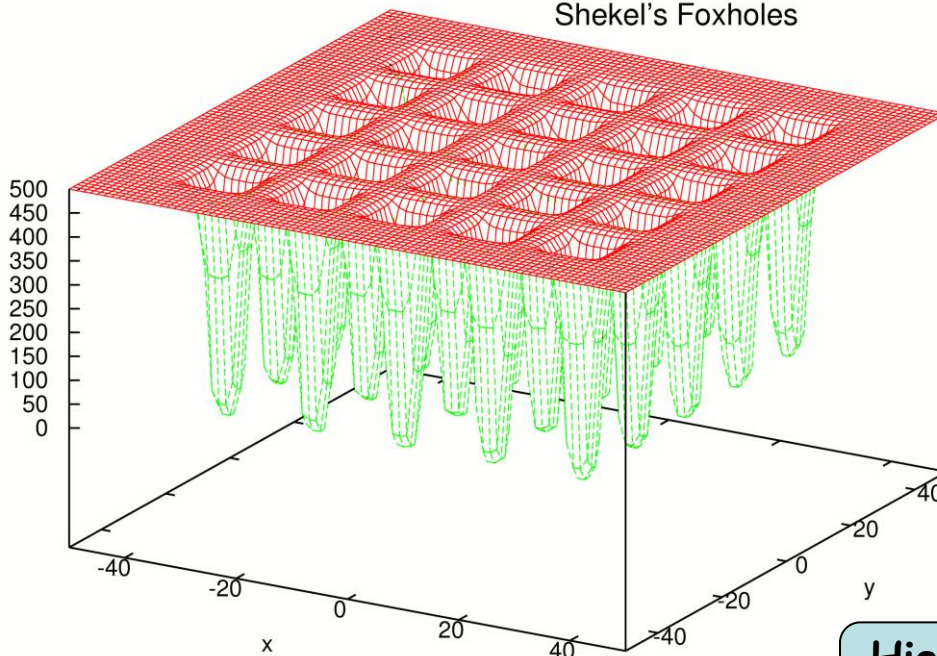
Lohnt der Aufwand der LSV-Suche den Nutzen? (4):

Testfunktionen: Shekel's Foxholes
(ein Albtraum für alle lokalen Suchverfahren)

Nur für zwei Dimensionen definiert


Shekel's Foxholes

Shekel's Foxholes
(rotated)



Das ist uns zu regelmäßig ...
... und damit zu einfach!

Hier ist übrigens
das Minimum!

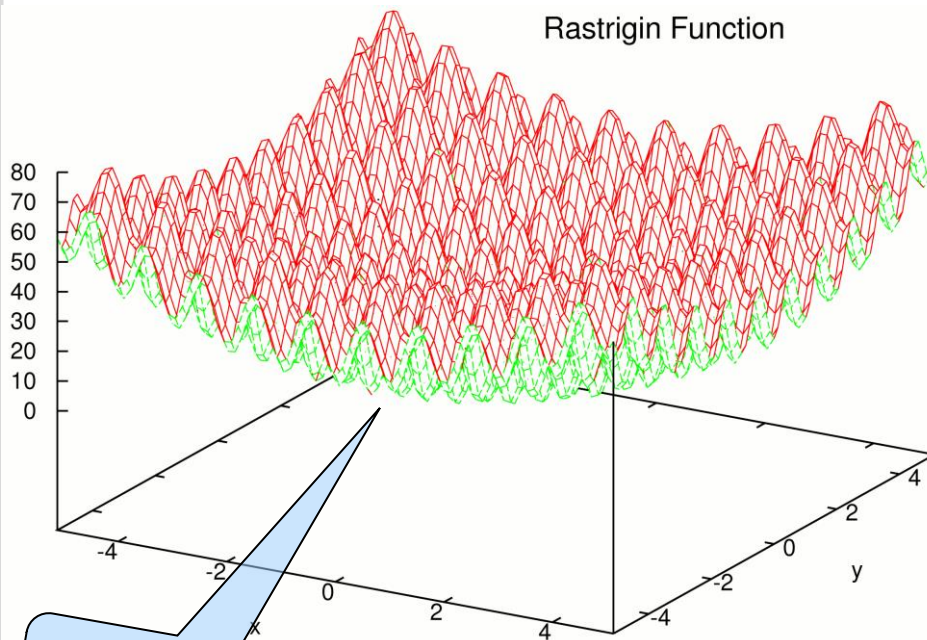


einfach drehen ...
... und schon wird es schwieriger!

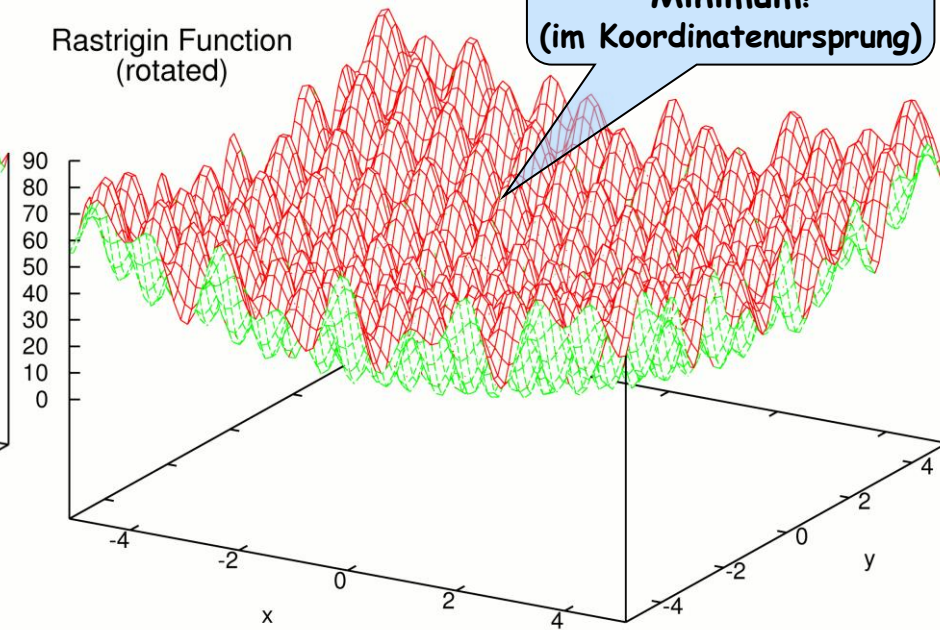
MA – Klassische MA – Lohnt der Aufwand?

Lohnt der Aufwand der LSV-Suche den Nutzen? (5):

Testfunktionen: Verallgemeinerte Rastrigin Funktion
(verallgemeinertes regelungstechnisches Problem, beliebig skalierbar)



Rastrigin Function
(rotated)




Auch diese Funktion ist zu regelmäßig und wird gedreht.

MA – Klassische MA – Lohnt der Aufwand?

Lohnt der Aufwand der LSV-Suche den Nutzen? (6):

Verglichen werden die benötigten Evaluationen zur Erreichung einer Zielqualität.

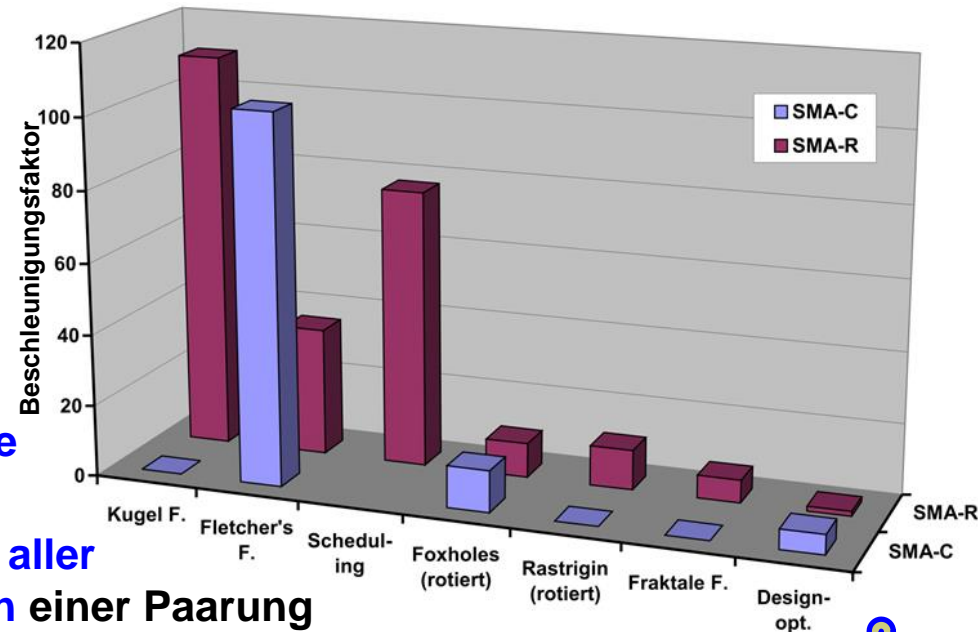


MA – Klassische MA – Lohnt der Aufwand?

Lohnt der Aufwand der LSV-Suche den Nutzen? (7):

Auswertung:

1. Unterschiede so deutlich, dass keine statistische Analyse erforderlich ist.
2. Ergebnisse basieren auf mühsamer Feineinstellung
 - der **Populationsgröße μ**
 - der **Rosenbrock-Abbruchschranke** (Intensität der lokalen Suche)
 - der Wahl zwischen **Verbesserung aller** oder nur des **besten Nachkommen** einer Paarung
 - der Wahl zwischen **Lamarckscher** oder **Baldwin Evolution** (Anpassung des Genotyps oder nicht)
3. SMA-R funktioniert in allen untersuchten Fällen.
4. SMA-C funktioniert nicht immer, aber wenn, dann mit besseren Ergebnissen!
5. Die Unterschiede zum EA sind zum Teil erheblich.



Führt zur Entscheidung zugunsten Lamarckscher Evolution

Konsequenz:

Die Vorteile des memetischen Ansatzes rechtfertigen den Versuch, die neuen Strategieparameter zu reduzieren. (Siehe Folie 9)

Überlegungen:

- Die lokale Suche kann anfänglich ungenau sein und muss erst im Laufe der Evolution präziser werden.
- Verschiedene LSV tragen unterschiedlich zum Erfolg bei. Das ist
 - anwendungsabhängig und
 - abhängig vom aktuellen Evolutionsfortschritt
- Lokale Suche verursacht **Kosten** (zusätzliche Evaluationen) und bringt **Nutzen** (Fitnessverbesserung)

Schlussfolgerung:

- Wiederholte Erfassung von Kosten und Nutzen zur Steuerung
 - der Intensität der lokalen Suche,
 - der LSV-Auswahl aus einer vorgegebenen Gruppe und
 - des Anteils verbesserter Nachkommen pro Paarung
- während des Optimierungslaufs (Adaption)**

Auswirkung auf die Strategieparameter (1):

1. Auswahl eines Verfahrens zur lokalen Suche
Reduktion auf die **Zusammenstellung erfolgversprechender Verfahren.**
Auswahl per Adaption.
2. Anpassung des Genotyps oder nicht (Lamarcksche vs. Baldwin-Evolution)?
Anpassung, da eine bessere Bewahrung der genotypischen Diversität bereits durch das Populationsmodell erreicht wird.
3. Wie werden die Nachkommen zur LSV-Verbesserung ausgewählt?
Der beste Nachkomme und der Rest per **adaptierter** Zufallsrate
4. Wie viel Nachkommen sollen verbessert werden?
Entscheidung zwischen
*nur der Beste einer Paarung ODER weitere Geschwister bei **adaptierter** Anzahl*
5. Wie genau soll die lokale Suche sein?
Adaptierte Anpassung

Auswirkung auf die Strategieparameter (2):

Verbleibende Strategieparameter:

- **Entscheidung:** Verbesserung des besten Nachkommen oder zusätzlich eines adaptierten Anteils der Geschwister
Empfehlung: Nur den Besten, solange keine erhebliche Multimodalität vermutet wird.
- **Einstellung:** Populationsgröße μ :
 - Erfahrungswerte:
 - bei Verbesserung des besten Nachkommen: 5 – 200
 - bei zusätzlicher Geschwisterverbesserung: 20 – 120
 - Bei geringerer erwarteter Komplexität mit den kleineren Populationsgrößen beginnen.
 - Bei allen multimodalen Testfällen gilt für gute Populationsgrößen:

$$\mu_{\text{weitere Geschwister verbessern}} \leq \mu_{\text{nur besten Nachkommen verbessern}}$$

[Jak10]

Adaptiver multimemetischer Algorithmus (AMMA):

Was kann man vom AMMA im Vergleich zum jeweils besten SMA erwarten?

- Verbesserung
wegen




- Verschlechterung
wegen



Auf jeden Fall kann man weniger mühsame manuelle Einstellarbeit erwarten!

Ergebnisse der Testfälle:



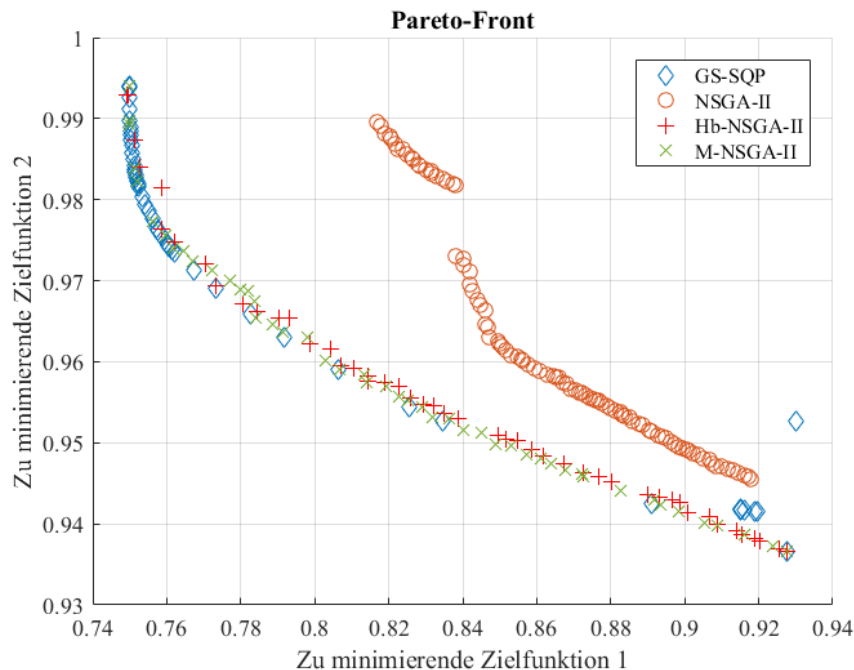
Zusammenfassung:

1. **Memetische Algorithmen** sind dem reinen EA in der Regel weit überlegen:
 - hinsichtlich der **Konvergenzgeschwindigkeit**
 - hinsichtlich der Bandbreite geeigneter **Populationsgrößen μ**
2. Die Auswahl geeigneter **Meme** ist wesentlich für den Erfolg.
3. Der **adaptive multimemetische Algorithmus**
 - kann fast alle neuen Strategieparameter selbstständig einstellen
 - liefert entweder eine bessere Performance als der SMA oder die Leistungsverluste sind angesichts der erreichten Vereinfachung akzeptabel.
4. Die Bewahrung genotypischer Diversität durch das **Diffusionsmodell** (Ring) erlaubt **Lamarcksche Evolution**.
5. Die **Initialisierung der Startpopulation** mit (heuristisch) vorgenerierten Individuen (max. ca. 20%) kann die Evolution erheblich beschleunigen.

Beispiel einer Pareto-Optimierung

Optimierung von Steuerkennfeldern und -kennlinien in der Antriebsstrangentwicklung

- Zwei mit Hilfe der gew. Summe aggregierte Kriterien, die dann zu minimieren sind
- Einsatz und Vergleich
 - eines lokalen gradientenbasierten Verfahrens und der gew. Gesamtsumme (**GS-SQP**)
 - des **NSGA-II** (Non-dominated Sorting Genetic Algorithm, siehe Kap.1, Folie 16)
 - von zwei Hybridisierungen: Vorooptimierung (**Hb-NSGA-II**) und SMA (**M-NSGA-II**)



Anmerkungen:

- **GS-SQP**: Viele Läufe mit äquidistanten Änderungen der Gewichte
- Aufwandsvergleich:
Hb-NSGA-II < **M-NSGA-II** < **NSGA-II** < **GS-SQP**
- Das LSV liefert bereits gute Ergebnisse, aber bei einer schlechten Verteilung auf der Front.
- Daher genügt bei dieser Anwendung die Vorooptimierung der Startpopulation.

